Junior ML Engineer

Начинающий ML-инженер · работа с базами данных · без коммерческого опыта

GitHub-портфолио: github.com/Amon-s1lver

Цель

Позиция Junior ML Engineer или стажёра в области машинного обучения и работы с данными. Хочу применять знания по ML на реальных задачах, развивать навыки работы с базами данных и пайплайнами обработки данных.

Образование

Университет Иннополис, 3 курс бакалавриата (неоконченное высшее), 2024 – 2028

Профильные дисциплины: Intro to ML · Технологии больших языковых моделей для задач исследований и разработки · Нейроэкономические модели выбора · Устойчивость, оценка и безопасность ИИ-агентов · Прикладная статистика в анализе данных

Навыки

Область	Навыки
Языки и библиотеки	Python, PyTorch, scikit-learn, pandas, NumPy, matplotlib
Базы данных	PostgreSQL, SQL: CTE, оконные функции, агрегаты, представления-витрины признаков
Машинное обучение	Обучение и сравнение моделей, кросс-валидация, нейронные сети, квантизация, устойчивость моделей (adversarial-атаки), NLP, работа с LLM, воспроизводимые эксперименты
Инструменты	Git, GitHub, Jupyter Notebook, Google Colab, Kaggle, VS Code, LaTeX

Soft skills: курс «Психология IT-специалиста»; командная работа (групповой проект по технологиям БЯМ, командный проект P14); оформление результатов — ноутбуки, таблицы сравнения моделей, отчёты, презентации.

Проекты

Квантованные функции активации (проект P14, командный, 2 человека — учебный исследовательский)

- Реализованы равномерное квантование выходов активации tanh, табличная (LUT) и кусочно-линейная (PWL) аппроксимации; полносвязная сеть 64→128→64→10 на NumPy, датасет digits, точность в float32 — 0,971
- При 1–2 битах на активацию точность около 0,960, при 4 и более битах ответы модели не меняются; PWL заметно точнее LUT при том же числе узлов
- Сравнены PTQ и QAT: для 2-битных весов QAT повысил точность с 0,927 до 0,980
- У LUT обнаружена маскировка градиента: наивная FGSM-атака даёт ложную устойчивость, STE-атака снижает точность до 0,062

Код и отчёт: github.com/Amon-s1lver/Amon-s1lver/tree/main/projects/P14-quantized-activations

Прогноз оттока клиентов: SQL-аналитика + ML (личный проект)

- Пайплайн: данные телеком-оператора (7043 клиента) в БД → SQL-аналитика (CTE, оконные функции, RANK) → SQL-витрина признаков → модели scikit-learn
- SQL-анализ: помесячный контракт даёт 42,7% оттока и 87% потерянной выручки, самый рискованный сегмент — 60%
- LogReg, Random Forest, Gradient Boosting: CV ROC-AUC ≈ 0,84; выбор порога по экономике удержания на out-of-fold предсказаниях дал +33% прибыли относительно порога 0,5

Код и SQL: github.com/Amon-s1lver/Amon-s1lver/tree/main/projects/churn-sql-ml

Детектор SMS-спама и его устойчивость к обфускации (личный проект)

- 4 модели: TF-IDF (слова / символы) + Naive Bayes / логистическая регрессия и CharCNN на PyTorch; лучшая — TF-IDF по символам, F1 = 0,969
- Атаки обфускацией (leetspeak, разбивка слов, гомоглифы): white-box атака снижает recall словесной модели с 0,926 до 0,736
- Защиты: нормализация текста и adversarial augmentation возвращают recall до 0,951; показано, что защиты не переносятся на новый тип атаки

Код: github.com/Amon-s1lver/Amon-s1lver/tree/main/projects/spam-robustness

Дополнительно

- Языки: русский — родной; английский — B2, чтение технической литературы
- Опыт коммерческой разработки: отсутствует, обучение через учебные и личные проекты